

Ćwiczenia 5 - Bioinformatyka 2

Zadanie 1

Prawdopodobnie przeprowadzono logarytmowanie wartości i normalizację danych.

To, że po normalizacji dane mają zbliżone średnie, pozwala na wiarygodne porównywanie ekspresji pojedynczych genów między różnymi grupami w celu identyfikacji różnic. Usunięto również błąd związany z różną ilością materiału genetycznego w różnych próbkach.

Zadanie 2

W oparciu o metodę SVM zbudowano model w postaci:

```
In [1]: def model(a, b, c):  
        return 0.6*a - 0.02*b - 0.4*c
```

Według osoba o następującym profilu ekspresji genów jest chora:

```
In [6]: chory = model(0.8, 0.7, 0.2)  
        print(round(chory, 2))
```

0.39

Oznacza to, że osoby które są powyżej zera są traktowane jako chore. Więc dla nowej osoby, musimy sprawdzić czy wynik dla osoby jest powyżej, czy poniżej zera.

Czy osoba o profilu ekspresji (A, B, C) = (0.8, 0.7, 0.2) jest chora?

```
In [ ]: osoba = model(0.6, 0.9, 0.4)  
        print(round(osoba, 2))  
  
        if osoba < 0:  
            print("Osoba jest zdrowa")  
        else:  
            print("Osoba jest chora")
```

0.18

Osoba jest chora

```
In [4]: def model_rekurencyjny(a, c):  
        return 0.6*a - 0.4*c
```

```
In [9]: osoba_rek = model_rekurencyjny(0.6, 0.4)  
        print(round(osoba_rek, 2))  
  
        if osoba < 0:  
            print("Osoba jest zdrowa")  
        else:  
            print("Osoba jest chora")
```

0.2

Osoba jest chora

a) Według modelu podanego powyżej, osoba z profilem ekspresji (0.6, 0.9, 0.4) została zakwalifikowana jako chora.

b) Po zmianie modelu poprzez metodę rekurencyjnej eliminacji cech uproszczono model o zmienną z najmniejszym współczynnikiem (B). Otrzymany wynik dalej kwalifikuję tą osobę jako chorą

Zadanie 3

Musimy wyznaczyć współczynnik korelacji pomiędzy poziomem ekspresji genu A i genu B. Następnie trzeba zinterpretować uzyskany wynik.

```
In [10]: gen_a = [0.7, 0.74, 0.90, 1.05, 1.2, 1.31]
gen_b = [1.5, 1.32, 1.1, 1.2, 0.72, 0.60]
```

```
In [18]: from scipy import stats


res = stats.spearmanr(gen_a, gen_b)
print(round(res.statistic, 3))
print(round(res.pvalue, 3))
```

-0.943

0.005

```
In [16]: import matplotlib.pyplot as plt

plt.scatter(gen_a, gen_b)
plt.xlabel("Gen A")
plt.ylabel("Gen B")
plt.title("Wykres poziomu ekspresji genów")
plt.show()
```



Z testu korelacji otrzymano wartość korelacji na poziomie -0.943 - oznacza to, że wraz ze wzrostem poziomu genu A, maleje poziom genu B. Nie powoduje to natomiast, że możemy być pewni, że wzrost poziomu genu B powoduje spadek poziomu genu A, ani analogicznie w drugą stronę.

P-value tego testu wynosi $0,005$, co przy założeniu alfa na poziomie 5% , potwierdza istotność otrzymanej korelacji.

Zadanie 4

Czego dotyczyło badanie?:

- Profilowania ekspresji genów w hipokampie (region mózgu kluczowy dla pamięci) u osób z chorobą Alzheimera na różnych etapach zaawansowania oraz u grupy kontrolnej

Gdzie badano ekspresje genów (materiał/tkanka)?:

- W tkance mózgowej, obszar CA1 hipokampa

Ile było wszystkich próbek i na ile grub były one podzielone?:

- **33** próbki podzielone na **4** grupy:
 - Control (Kontrola) - 9 osób
 - Incipient AD - 7 osób
 - Moderate AD - 8 osób

- Severe AD - 7 osób

Według jakich kryteriów podzielono próbki na grupy? Opisz wykorzystane parametry:

- **MMSE:** MiniMental Status Examination. Im niższy wynik, tym gorszy stan pacjenta
- **NFT Score:** Im wyższy wynik, tym większe zniszczenie neuronów

Podaj przykład genów różnicujących?:

- Query: "**disease state**"[FINF] AND GDS810[ACCN] AND "**up down genes**"[filter]" - sortowane po subgroup effect
 - XIST
 - COL5A2
 - LOC101060363

Jak wygląda przebieg ekspresji dla genów SPARC, VSNL1 oraz COL5A2 w kolejnych grupach?:

- **SPARC:**
 - Obserwuje się wyraźny **wzrost** ekspresji korelujący z postępem choroby
- **VSNL1:**
 - Wykazuje istotny **spadek** ekspresji, wraz z zaawansowaniem choroby
- **COL5A2:**
 - Wykazuje **spadek** ekspresji korelujący z postępem choroby

Czy obserwujesz jakieś tendencje zmiany poziomu ich ekspresji w kolejnych grupach?:

- Tak, zmiany te nie są skokowe, lecz wykazują skorelowany gradient.
- Występuje silna negatywna korelacja między markerami neuronalnymi VSNL1 i COL5A2 (spadek wraz z chorobą) a SPARC (wzrost wraz z chorobą)

Poszukaj w źródłach zewnętrznych informacji za co odpowiadają te geny oraz ich związku z chorobą Alzheimera.:

- **SPARC** (secreted protein acidic and cysteine rich): białko zewnątrzkomórkowe, które reguluje interakcje między komórkami a otaczającą macierzą zewnątrzkomórkową
- **VSNL1** (visinin like 1): białko wiążące wapń, które należy do rodziny białek czujników wapnia i występuje w mózgu
- **COL5A2** (collagen type V alpha 2 chain): gen kodujący podjednostkę typu V kolagenu, który jest ważnym elementem tkanki łącznej i odgrywa rolę w tworzeniu macierzy zewnątrzkomórkowej

Czym są housekeeping genes? Jaką pełnią rolę w ekspresymencie mikromacierzowym?:

- Są to geny podstawowe (metaboliczne), niezbędne do życia komórki, których ekspresja jest stała
- Służą do normalizacji danych. Pozwalają skorygować błędy techniczne wynikające z różnej ilości materiału genetycznego lub różnej wydajności reakcji

Wybierz trzy przykładowe geny tej kategorii i sprawdź ich ekspresję w kolejnych próbkach. Jaka ona jest?:

Wybrano geny: **UBC** (ubikwityna-c), **ACTB** (b-aktyna), **ALB** (albumina).

- Profile ekspresji tych genów są na podobnym poziomie we wszystkich grupach.

Zadanie 5

Jakie 3 procesy biologiczne mają najmniejszy FDR (false discovery rate) w rozważanej grupie genów?

- Regulation of miRNA transcription
- Positive regulation of miRNA transcription
- Heart valve morphogenesis

Która funkcja molekularna ma najmniejszy FDR (false discovery rate) w rozważanej grupie genów?

- DNA-binding transcription activator activity, RNA polymerase II-specific

Która ścieżka KEGG ma najmniejszy FDR (false discovery rate) w rozważanej grupie genów?

- MicroRNAs in cancer

Zadanie 6

Należy skomentować i porównać poniższe wyniki w kontekście powyższych informacji. W jaki sposób podzieliłbym rozważane chwile czasowe?

Komentarz:

- **Mikromacierz:** Widoczne jest silne odwrócenie wzorca ekspresji. Geny aktywne w pierwszych chwilach ulegają wyciszeniu w późniejszym czasie, zamieniając się z drugą grupą genów, która aktywuje się w ostatniej fazie. Oznacza to globalne przełączenie ekspresji genów.
- **PCA:** Układ punktów tworzy podkowę co może świadczyć o tym, że proces jest ciągły i postępujący w czasie, a nie skokowy.
- **Mapy Kohonena:** Żółte pola wysokiej ekspresji przesuwają się pomiędzy mapami. Mapy 1-3 są do siebie podobne, Mapa 4 jest przejściowa, a Mapy 5-7 tworzą nowy wzór.

W jaki sposób podzieliłbym rozważane chwile czasowe?

- **Faza I (1, 2, 3):**
 - Dominacja genów pierwszej klasy.
 - Intensywna glikoliza, szybki wzrost biomasy na glukozie.
- **Faza II (4):**
 - Punkt zwrotny. Ekspresja genów glikolitycznych spada, a geny fermentacyjne/stresowe zaczynają się aktywować.
 - **Interpretacja biologiczna:** Wyczerpanie glukozy w pożywce, stres metaboliczny.
- **Faza III (5, 6):**
 - Dominacja genów drugiej klasy.
 - **Interpretacja biologiczna:** Stabilny metabolizm oparty na fermentacji alkoholowej lub oddychaniu produktami fermentacji.

Zadanie 7

Wejść na stronę https://singlecell.broadinstitute.org/single_cell/. Znajdą się tam dane z eksperymentów scRNA-seq. Wyszukać eksperyment: "*Single-cell transcriptomics of the spinal cord of a severe SMA mouse*" i odpowiedz na poniższe pytania.

Czego dotyczył eksperyment? (Summary)

- Eksperyment polegał na analizie zmian ekspresji genów na poziomie pojedynczych komórek w rdzeniu kręgowym mysiego modelu z SMA. Zastosowano technikę sekwencjonowania scRNA-seq w celu zidentyfikowania typów komórek, jak i ich różnicowo ekspresjonowane geny.

Ile komórek i genów rozważano?

- 22155 komórek
- 18772 genów

Ile typów komórek rozważano?

- 10 typów komórek (*astrocyte, blood, COP, ependymal, microglia, neuron, oligo, OPC, schwann cells, vasculature*)

Dodatkowo, sprawdzić ekspresję genów: hemoglobiny (HBB) oraz SPARC wśród rozważanych typów komórek.

W której grupie występuje największa ich ekspresja? (Explore, search genes):

- SPARC: Vasculature
- HBB: komórki krwi (blood)